

1. (a) Avec un paramètre de régularisation de $\lambda = 0$, il s'agit d'une régression linéaire simple. On a alors

$$\hat{\beta}_1 = \frac{\sum_{i=1}^8 X_i Y_i}{\sum_{i=1}^8 X_i^2} = \frac{35}{16} = 2.1875$$

$$\hat{\beta}_0 = \frac{\sum_{i=1}^8 Y_i}{8} = 40.$$

Ainsi, l'équation du modèle est $\hat{Y} = 40 + 2.1875X$.

- (b) Pour la régression Ridge en général, on a vu que l'ordonnée à l'origine n'était pas affectée et donc que $\hat{\beta}_0 = 40$. La solution générale, en dimension p , est

$$\hat{\beta}^R = \left(\mathbf{X}^{**T} \mathbf{X}^{**} + \lambda \mathbf{I}_p \right)^{-1} \mathbf{X}^{**T} \mathbf{Y}$$

qui devient, lorsque $p = 1$,

$$= \frac{\sum_{i=1}^8 X_i Y_i}{\sum_{i=1}^8 X_i^2 + \lambda(1)}$$

$$= \frac{35}{16 + \lambda}.$$

Pour $\lambda = 4$, on obtient $\hat{\beta}_1 = 1.75$ (la valeur est, comme prévue, plus près de 0 que celle obtenue dans la régression linéaire classique). L'équation du modèle est alors $\hat{Y} = 40 + 1.75X$. On pouvait également utiliser cette approche pour trouver la solution à la sous-question précédente.

Par la suite, on obtient les prédictions et on calcule l'erreur quadratique moyenne :

$$\hat{Y}_1 = 40 + 1.75(-2) = 36.5$$

$$\hat{Y}_2 = \hat{Y}_3 = \hat{Y}_4 = 38.25$$

$$\hat{Y}_5 = 40.00$$

$$\hat{Y}_6 = 41.75$$

$$\hat{Y}_7 = \hat{Y}_8 = 43.50$$

$$\rightarrow MSE = \frac{\sum_{i=1}^8 (\hat{Y}_i - Y_i)^2}{8}$$

$$= 1.8125.$$

2. (a) Pour trouver un optimum de la fonction objectif, on calcule la dérivée partielle par rapport à

β_0

$$\begin{aligned}
& \frac{\partial}{\partial \beta_0} \left(\sum_{i=1}^n \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right) \\
&= \sum_{i=1}^n 2 \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right) (-1) = 0 \\
&\rightarrow \sum_{i=1}^n Y_i - n\beta_0 - \sum_{i=1}^n \sum_{j=1}^p \beta_j X_{ij} = 0 \\
&\rightarrow \hat{\beta}_0 = \frac{\sum_{i=1}^n Y_i}{n} - \sum_{j=1}^p \beta_j \frac{\sum_{i=1}^n X_{ij}}{n} \\
&\rightarrow \hat{\beta}_0 = \bar{Y} - \sum_{j=1}^p \beta_j \bar{X}_j.
\end{aligned}$$

Le calcul de la dérivée seconde permet de vérifier qu'il s'agit bien d'un minimum local

$$\begin{aligned}
& \frac{\partial^2}{\partial \beta_0^2} \left(\sum_{i=1}^n 2 \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right) (-1) \right) \\
&= 2n > 0.
\end{aligned}$$

(b) On a

$$\begin{aligned}
& \arg \min_{\beta_0, \dots, \beta_p} \sum_{i=1}^n \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \\
& \arg \min_{\beta_1, \dots, \beta_p} \sum_{i=1}^n \left(Y_i - \bar{Y} - \sum_{j=1}^p \beta_j \bar{X}_j - \sum_{j=1}^p \beta_j X_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \\
& \arg \min_{\beta_1, \dots, \beta_p} \sum_{i=1}^n \left(Y_i^* - \sum_{j=1}^p \beta_j X_{ij}^* \right)^2 + \lambda \sum_{j=1}^p \beta_j^2.
\end{aligned}$$

(c) On a (il faut se rappeler un peu comment faire du calcul matriciel¹ de base, sinon ça devient un peu lourd...)

$$\begin{aligned}
& \arg \min_{\beta^*} (\mathbf{Y}^* - \mathbf{X}^* \beta^*)^T (\mathbf{Y}^* - \mathbf{X}^* \beta^*) + \lambda \beta^{*T} \beta^* \\
& \arg \min_{\beta^*} \mathbf{Y}^{*T} \mathbf{Y}^* - 2\beta^{*T} \mathbf{X}^{*T} \mathbf{Y}^* + \beta^{*T} \mathbf{X}^{*T} \mathbf{X}^* \beta^* + \lambda \beta^{*T} \mathbf{I}_p \beta^* \\
& \frac{\partial}{\partial \beta^*} \left(\mathbf{Y}^{*T} \mathbf{Y}^* - 2\beta^{*T} \mathbf{X}^{*T} \mathbf{Y}^* + \beta^{*T} \mathbf{X}^{*T} \mathbf{X}^* \beta^* + \lambda \beta^{*T} \mathbf{I}_p \beta^* \right) \\
&= -2\mathbf{X}^{*T} \mathbf{Y}^* + 2\mathbf{X}^{*T} \mathbf{X}^* \beta^* + 2\lambda \mathbf{I}_p \beta^* = 0 \\
&\rightarrow \hat{\beta}^* = \left(\mathbf{X}^{*T} \mathbf{X}^* + \lambda \mathbf{I}_p \right)^{-1} \mathbf{X}^{*T} \mathbf{Y}^*.
\end{aligned}$$

3. (a) Le code permettant d'importer et de construire la base de données est présenté à la Figure 1.

(b) Le code permettant d'ajuster le modèle est présenté à la Figure 2.

(c) i. Avec les résultats présentés à la Figure 2, on a, pour Y , le cout total d'un sinistre (sachant qu'il y a eu sinistre), on a

$$\begin{aligned}
E[Y] &= \exp(7.5711 - 0.0008 * 400 - 0.0449 + 0.0321 + 0.3270 * 45 * 0.0137) \\
&= 1\,702.572.
\end{aligned}$$

1. N'hésitez pas à vérifier en dimension 2 les propriétés dont vous n'êtes pas certaine ou certain.

```
data(freMPL3)
data <- freMPL3
data <- data[data$ClaimAmount > 0,]
```

FIGURE 1 – Code informatique.

```
data1 <- data[,c(1,2,5,6,7,8,10,21)]
head(data1)

modele1 <- glm(ClaimAmount ~ LicAge + VehAge + Gender + MariStat + SocioCateg
               + DrivAge, family = Gamma(link = "log"), data = data1,
               offset = log(Exposure))
summary(modele1)
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	7.5710910	0.3240725	23.362	< 2e-16	***
LicAge	-0.0008203	0.0007727	-1.062	0.288630	
VehAge1	0.1294967	0.1574067	0.823	0.410847	
VehAge10+	-0.1471522	0.3170181	-0.464	0.642605	
VehAge2	-0.0980039	0.1566142	-0.626	0.531586	
VehAge3	-0.0448791	0.1695603	-0.265	0.791302	
VehAge4	-0.1953874	0.1713965	-1.140	0.254522	
VehAge5	0.7147311	0.1907686	3.747	0.000188	***
VehAge6-7	0.4353038	0.1915252	2.273	0.023210	*
VehAge8-9	0.2439549	0.2466899	0.989	0.322902	
GenderMale	0.0321148	0.0978605	0.328	0.742840	
MariStatOther	0.2287443	0.1209635	1.891	0.058859	.
SocioCategCSP20	0.0255151	0.8166161	0.031	0.975079	
SocioCategCSP21	-1.4977180	1.6061031	-0.933	0.351255	
SocioCategCSP22	-0.6301074	1.1438103	-0.551	0.581814	
SocioCategCSP26	0.4710595	0.3158833	1.491	0.136156	
SocioCategCSP37	0.0138807	0.4183706	0.033	0.973538	
SocioCategCSP42	-0.1137252	0.3396833	-0.335	0.737835	
SocioCategCSP46	0.0694105	0.3664637	0.189	0.849806	
SocioCategCSP47	-1.1527185	1.1430011	-1.009	0.313414	
SocioCategCSP48	0.1746436	0.3388862	0.515	0.606405	
SocioCategCSP49	-0.1603568	0.4584226	-0.350	0.726548	
SocioCategCSP50	0.3269536	0.2057376	1.589	0.112280	
SocioCategCSP55	0.1298638	0.2479113	0.524	0.600491	
SocioCategCSP6	-0.8686871	0.7359607	-1.180	0.238094	
SocioCategCSP60	-0.0116380	0.2485941	-0.047	0.962668	
SocioCategCSP65	-0.4241183	1.1552812	-0.367	0.713599	
SocioCategCSP66	0.0827468	0.3305943	0.250	0.802400	
SocioCategCSP74	-3.4982896	1.1484951	-3.046	0.002369	**
SocioCategCSP77	-2.1169095	0.8202913	-2.581	0.009977	**
DrivAge	0.0137474	0.0091838	1.497	0.134671	

FIGURE 2 – Code informatique.

- ii. Le coefficient associé à la variable **DrivAge** n'a pas une valeur significativement différente de 0 (la valeur p du test est supérieure à 0.05).
- (d) Le code permettant de sélectionner la valeur de $K = 10$ à l'aide du critère AIC est présenté à la Figure 3. Le code permettant de sélectionner la valeur de $K = 2$ à l'aide du critère MSE et de la 2-validation croisée est présenté à la Figure 4.

```

data1$DrivAge2 <- data1$DrivAge^2
data1$DrivAge3 <- data1$DrivAge^3
data1$DrivAge4 <- data1$DrivAge^4
data1$DrivAge5 <- data1$DrivAge^5
...

M1 <- glm(ClaimAmount ~ DrivAge, family = Gamma(link = "log"), data = data1,
  offset = log(Exposure))$aic
M2 <- glm(ClaimAmount ~ DrivAge + DrivAge2, family = Gamma(link = "log"),
  data = data1, offset = log(Exposure))$aic
M3 <- glm(ClaimAmount ~ DrivAge + DrivAge2+ DrivAge3, family = Gamma(link = "log"),
  data = data1, offset = log(Exposure))$aic
M4 <- glm(ClaimAmount ~ DrivAge + DrivAge2 + DrivAge3 + DrivAge4,
  family = Gamma(link = "log"), data = data1, offset = log(Exposure))$aic
...

c(M1, M2, M3, M4, M5, M6, M7, M8, M9, M10)
22004.34 22005.14 22007.08 22008.74 22010.35 22011.74 22013.72
22014.87 22005.53 21994.72

```

FIGURE 3 – Code informatique.

```

### Création de deux bases pour la 2-validation croisée
set.seed(100)
indice <- sample(1:length(data1$Exposure), 623, replace = FALSE)
dataA <- data1[indice,]
dataB <- data1[-indice,]

### Fonction qui calcule le MSE pour chacun des modèles avec x comme
### base d'entraînement et y comme base d'évaluation

FUN <- function(x, y)
{
  M1 <- glm(ClaimAmount ~ DrivAge, family = Gamma(link = "log"), data = x,
    offset = log(Exposure))
  M2 <- glm(ClaimAmount ~ DrivAge + DrivAge2, family = Gamma(link = "log"),
    data = x, offset = log(Exposure))
  M3 <- glm(ClaimAmount ~ DrivAge + DrivAge2+ DrivAge3, family = Gamma(link = "log"),
    data = x, offset = log(Exposure))
  M4 <- glm(ClaimAmount ~ DrivAge + DrivAge2 + DrivAge3 + DrivAge4,
    family = Gamma(link = "log"), data = x, offset = log(Exposure))
  ...
  MSE1 <- mean((predict(M1, newdata = y, type = "response") - y$ClaimAmount)^2)
  MSE2 <- mean((predict(M2, newdata = y, type = "response") - y$ClaimAmount)^2)
  MSE3 <- mean((predict(M3, newdata = y, type = "response") - y$ClaimAmount)^2)
  MSE4 <- mean((predict(M4, newdata = y, type = "response") - y$ClaimAmount)^2)
  ...
  c(MSE1, MSE2, MSE3, MSE4, MSE5, MSE6, MSE7, MSE8, MSE9, MSE10)
}

(FUN(dataA, dataB) + FUN(dataB, dataA))/2

```

FIGURE 4 – Code informatique.

(e) Le code permettant d'obtenir le modèle Ridge et les résultats sont présentés à la Figure 5.

```
X <- as.matrix(data1[,c(2,7)])
Y <- round(as.matrix(data1[,8]),0)
OS <- as.matrix(data1[,1])

cv.fit <- cv.glmnet(X, Y, nfolds = 10, alpha = 0, family = "poisson",
                    offset = log(OS))

coef(cv.fit)
               1
(Intercept) 8.042979e+00
LicAge      2.099967e-38
DrivAge     1.168982e-36

cv.fit$lambda.min
18376.2
```

FIGURE 5 – Code informatique.

(f) Le code permettant d'obtenir le modèle Ridge et les résultats sont présentés à la Figure 6.

```
### Pour utiliser la fonction cv.glmnet avec une (ou plusieurs) variables
### explicatives catégorielles, il faut construire manuellement les
### variables dichotomiques avec la fonction model.matrix
X <- model.matrix(~VehUsage - 1, data = data)
head(X, 3)
  VehUsagePrivate VehUsagePrivate+trip to office VehUsageProfessional
           0           0           1
           1           0           0
           0           0           1
  VehUsageProfessional run
35                0
52                0
60                0

Y <- round(as.matrix(data1[,8]),0)
OS <- as.matrix(data1[,1])
cv.fit <- cv.glmnet(X, Y, nfolds = 10, alpha = 0, family = "poisson",
                    offset = log(OS))

coef(cv.fit)

(Intercept)                8.042979e+00
VehUsagePrivate             9.611938e-35
VehUsagePrivate+trip to office 8.361573e-35
VehUsageProfessional        -1.952645e-34
VehUsageProfessional run    -2.098311e-34
```

FIGURE 6 – Code informatique.

4. On a

$$\begin{aligned}
 \hat{\beta}^R &= (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{Y} \\
 &= (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}^T \mathbf{X}) (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \\
 &= (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\beta}.
 \end{aligned}$$

Si $\lambda = 0$, alors on a

$$E[\hat{\beta}^R] = E[\hat{\beta}] = \beta$$

et sinon

$$E[\hat{\beta}^R] = E[(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\beta}] \neq \beta.$$

5. (a) Le code permettant d'obtenir les résultats es présenté à la Figure 7 et le graphique est présenté à la Figure 8. On observe qu'une valeur $\alpha = 0$ est optimale et que le modèle est en fait

```
library(ggplot2)

data(mtcars)

X <- model.matrix(mpg ~ ., data=mtcars)[-1]
Y <- mtcars$mpg

alphas <- seq(0, 1, by=.01)
mses <- numeric(101)

for(i in 1:101){
  cvfits <- cv.glmnet(X, Y, alpha = alphas[i], nfolds = 32)
  loc <- which(cvfits$lambda == cvfits$lambda.min)
  mses[i] <- cvfits$cvm[loc]
}

RES <- data.frame(mse=mses, alpha=alphas)

plot1 <- ggplot(RES, aes(x=alpha, y=mse)) +
  geom_point(shape=1) +
  ylab("MSE (validation croisée)") +
  xlab("alpha") +
  ggtitle("")
plot1
```

FIGURE 7 – Code informatique.

purement Ridge. Ce résultat s'explique probablement par la forte multicollinéarité présente dans les données.

- (b) Le code permettant d'obtenir les résultats es présenté à la Figure 9 et le graphique est présenté à la Figure 10. On observe qu'une valeur $\alpha = 1$ est optimale et que le modèle est en fait purement Lasso.




FIGURE 8 – Évolution de l'erreur quadratique moyenne en fonction de la valeur de α .

```
load("/.../QuickStartExample.RData")

X <- x
Y <- y

alphas <- seq(0, 1, by=.01)
mses <- numeric(101)

for(i in 1:101){
  cvfits <- cv.glmnet(X, Y, alpha = alphas[i], nfolds=100)
  loc <- which(cvfits$lambda==cvfits$lambda.min)
  mses[i] <- cvfits$cvm[loc]
}

RES <- data.frame(mse=mses, alpha=alphas)

plot1 <- ggplot(RES, aes(x = alpha, y = mse)) +
  geom_point(shape = 1) +
  ylab("Erreur quadratique moyenne") +
  xlab("alpha") +
  ggtitle("")

plot1
```

FIGURE 9 – Code informatique.




FIGURE 10 – Évolution de l'erreur quadratique moyenne en fonction de la valeur de α .